

Внедрение ML алгоритмов в агентную модель

1 Интеграция методов машинного обучения в агентную модель

1.1 Мотивация применения машинного обучения

Разработанная агент-ориентированная макроэкономическая модель реализована в виде системы взаимодействующих агентов (домохозяйства, фирмы и банк), чьи состояния и переходы формализованы явно и обновляются в дискретном времени. Поведение фирм в модели определяется набором rule-based правил, реализованных в модуле `agents.py`, включая процедуры адаптации занятости, производства и ценообразования.

В частности, правило формирования цены фирмы задаётся аналитически и использует ограниченный набор текущих состояний фирмы, таких как объём запасов и ожидаемый спрос. Данное правило является фиксированным по форме и не адаптируется к изменению макроэкономического режима, за исключением параметрической подстройки. Это ограничение становится существенным в условиях, когда модель демонстрирует многорежимную динамику.

Наличие таких режимов подтверждается результатами анализа чувствительности модели. В ходе вычислительного эксперимента с использованием Latin Hypercube Sampling (скрипт `scripts/run_lhs.py`) было сгенерировано множество параметрических конфигураций и соответствующих макроэкономических траекторий. Агрегированные результаты сохранены в файлах `lhs_runs.csv` (`wave1`) и `lhs_runs_wave2.csv` (`wave2`).

Анализ этих данных показывает, что при различных значениях параметров модель воспроизводит как устойчивые режимы с положительными значениями выпуска и занятости, так и депрессивные режимы с нулевой экономической активностью. Например, доля прогонов с нулевой средней занятостью в `wave1` составляет 25.0%, а после сужения параметров в `wave2` снижается до 21.8% (см. `calibration_summary.md`). Аналогичное поведение наблюдается для выпуска и потребления.

Дополнительное подтверждение сложности и нелинейности модели даёт суррогатное моделирование. В скрипте `scripts/train_emulator.py` для агрегированных

характеристик модели обучается Gaussian Process Regression. Качество аппроксимации по кросс-валидации характеризуется средним значением коэффициента детерминации $R^2 = 0.64$ и медианным значением $R^2 = 0.76$ (файл `emulator_scores.csv`). Эти результаты указывают на наличие устойчивых, но нелинейных зависимостей между параметрами модели и её макроэкономическими выходами.

Полученные результаты имеют важное следствие для спецификации поведения агентов. С одной стороны, динамика модели не является хаотической и допускает аппроксимацию. С другой стороны, сложность зависимостей между состояниями агентов и их решениями затрудняет задание универсальных аналитических правил, корректно работающих во всех режимах экономики.

В этой связи методы машинного обучения рассматриваются как инструмент аппроксимации сложных поведенческих правил на микроуровне. Машинное обучение в данной работе не используется для прямого прогнозирования макроэкономических показателей и не заменяет агентную модель в целом. Его применение ограничено аппроксимацией отдельного поведенческого перехода фирмы — правила формирования ценовой надбавки — на основе эндогенно сформированных данных, полученных в ходе устойчивых и экономически допустимых прогонов модели.

1.2 Постановка задачи машинного обучения

Задача машинного обучения в рамках агентной модели формулируется как задача аппроксимации правила формирования ценовой надбавки фирмы на основе её текущего состояния и условий экономической среды. Машинное обучение используется для замены аналитического правила ценообразования, реализованного в базовой версии модели, на данно-ориентированное отображение, обученное на эндогенно сформированных траекториях агентной динамики.

На уровне реализации ML-политика применяется на уровне отдельного агента фирмы и используется при вычислении цены продукции. Соответствующая модель обучается в скрипте `scripts/train_firm_policy.py`, где явно задан набор входных признаков и целевая переменная (листинг 1).

```
1 FEATURES = [  
2     "inventory",  
3     "last_demand",  
4     "cash",  
5     "debt",  
6     "price",  
7     "n_workers",  
8     "bank_available_credit",  
9     "wage",  
10 ]
```

Листинг 1: Набор признаков ML-политики фирмы

Каждый признак в данном векторе соответствует наблюдаемому состоянию фирмы или внешнему ограничению, уже присутствующему в формализации агентной модели. В частности, признаки `inventory` и `last_demand` отражают реальные рыночные условия, `cash` и `debt` — финансовое положение фирмы, `price` и `n_workers` — текущее состояние производственного решения, а `bank_available_credit` и `wage` — институциональные ограничения со стороны банковского сектора и рынка труда.

Целевой переменной задачи машинного обучения является реализованная ценовая надбавка фирмы (`realized_markup`), вычисляемая в ходе функционирования агентной модели. В скрипте обучения целевая переменная дополнительно ограничивается по диапазону значений для предотвращения влияния экстремальных выбросов (листинг 2).

```
1 X = df[FEATURES].to_numpy()
2 y = df["realized_markup"].clip(0.0, 0.5).to_numpy()
```

Листинг 2: Формирование целевой переменной ML-модели

Таким образом, задача машинного обучения формализуется как задача регрессии вида

$$m_i(t) = f(Q_i(t), D_i^{\text{last}}(t), C_i(t), L_i(t), p_i(t), N_i(t), \text{credit}(t), w(t)),$$

где функция $f(\cdot)$ аппроксимируется моделью машинного обучения.

Здесь $m_i(t)$ соответствует целевой переменной `realized_markup`, а остальные аргументы функции $f(\cdot)$ являются экономической интерпретацией признаков, используемых в обучающем датасете `firm_policy.csv` (см. листинг 1).

Принципиально важно, что целевая переменная не является нормативно заданной и не получается в результате решения задачи оптимизации. Она отражает фактически реализованное поведение фирмы в агентной модели, сформированное в результате взаимодействия с домохозяйствами, другими фирмами и банковским сектором. Следовательно, ML-модель обучается на эндогенных данных и аппроксимирует имплицитное поведенческое правило, уже присутствующее в динамике модели.

Дополнительно постановка задачи машинного обучения согласуется с результатами анализа чувствительности и `history matching`. Обучение ML-политики проводится на данных, полученных из прогонов, принадлежащих области допустимых параметрических конфигураций (NROY), что обеспечивает согласованность ML-решений с откалиброванной версией агентной модели и снижает риск обучения на неэкономичных режимах.

1.3 Формирование обучающей выборки

Обучающая выборка для модели машинного обучения формируется исключительно на основе данных, полученных в ходе функционирования агентной модели. В качестве источника данных используются длительные репрезентативные прогоны, отобранные после процедуры *history matching* и сохранённые в виде временных рядов состояний модели.

Формирование датасета реализовано в скрипте `scripts/build_firm_policy_dataset.py`. Входными данными для данного скрипта являются файлы вида `rep_run_XX_seedY.csv`, полученные в результате повторных прогонов модели для репрезентативных параметрических конфигураций и различных значений случайного зерна. Список используемых репрезентативных точек и соответствующих прогонов зафиксирован в файлах `representative_points.csv` и `representative_summary.csv`.

Каждый файл `rep_run_XX_seedY.csv` содержит временные ряды агрегированных и агент-уровневых характеристик модели. В процессе построения обучающей выборки скрипт последовательно проходит по временным шагам симуляции и извлекает состояния всех фирм, присутствующих в модели на данном шаге, а также соответствующее реализованное ценовое решение.

Для снижения влияния переходных процессов и инициализационных эффектов используется только хвостовая часть временного ряда. Данный выбор согласуется с методологией анализа чувствительности, применяемой ранее при вычислении агрегированных характеристик модели, где макроэкономические показатели также усредняются по последнему временному окну симуляции. Таким образом, в обучающую выборку включаются наблюдения, соответствующие квазистационарному режиму функционирования экономики.

На каждом временном шаге t и для каждой фирмы i формируется одна обучающая запись, включающая вектор признаков и целевую переменную. Вектор признаков полностью совпадает с набором входов, используемых в скрипте обучения ML-модели, и включает следующие компоненты:

- `inventory` — объём запасов готовой продукции фирмы;
- `last_demand` — последнюю оценку спроса;
- `cash` — объём денежных средств фирмы;
- `debt` — величину задолженности;
- `price` — текущую цену продукции;
- `n_workers` — численность работников;
- `bank_available_credit` — доступный объём банковского кредита;

- `wage` — уровень заработной платы.

Целевой переменной является `realized_markup`, вычисляемая на основе фактической цены и издержек производства фирмы на данном шаге симуляции. Данная величина отражает реализованное поведение фирмы и формируется эндогенно в процессе агентной динамики, без использования внешних эмпирических данных.

Результатом работы скрипта является единый датасет `firm_policy.csv`, содержащий совокупность наблюдений вида $\{\mathbf{x}_i(t), m_i(t)\}$ для различных фирм, временных шагов, репрезентативных параметрических конфигураций и значений случайного зерна. Полученная выборка используется в дальнейшем для обучения модели машинного обучения и полностью согласована с институциональными, финансовыми и балансовыми ограничениями агентной модели.

Таким образом, обучающая выборка отражает устойчивые закономерности поведения фирм в экономически допустимых режимах модели и обеспечивает корректную основу для аппроксимации правила ценообразования с помощью методов машинного обучения.

1.4 Архитектура и обучение модели машинного обучения

Для аппроксимации правила ценообразования фирмы используется модель градиентного бустинга над деревьями решений, реализованная с помощью класса `GradientBoostingRegressor` из библиотеки `scikit-learn`. Обучение модели выполняется в скрипте `scripts/train_firm_policy.py`, который принимает на вход сформированный датасет состояний фирм и сохраняет обученную модель в сериализованном виде.

Ниже приведён ключевой фрагмент кода, определяющий архитектуру и процедуру обучения модели (листинг 3):

```

1 from sklearn.ensemble import GradientBoostingRegressor
2
3 X = df[FEATURES].to_numpy()
4 y = df["realized_markup"].clip(0.0, 0.5).to_numpy()
5
6 model = GradientBoostingRegressor(random_state=0)
7 model.fit(X, y)
8
9 model.feature_order_ = list(FEATURES)
10 joblib.dump(model, out_path)

```

Листинг 3: Обучение ML-политики фирмы

Таким образом, используется стандартная конфигурация градиентного бустинга без дополнительной настройки гиперпараметров. Выбор данной архитектуры обусловлен необходимостью получить устойчивую и воспроизводимую аппроксимацию

поведенческого правила фирмы при умеренном объёме и шумности обучающей выборки. Фиксация параметра `random_state=0` обеспечивает детерминированность результатов обучения при повторных запусках.

Обучение производится на датасете `firm_policy.csv`, сформированном на предыдущем этапе. Перед обучением выполняется проверка наличия всех необходимых признаков и целевой переменной, что предотвращает использование некорректных или неполных данных. Целевая переменная `realized_markup` принудительно ограничивается диапазоном $[0, 0.5]$, что отражает институциональные ограничения поведения фирм в агентной модели и предотвращает влияние редких экстремальных наблюдений на процесс обучения.

Результатом работы скрипта является файл `firm_policy.pkl`, содержащий обученную модель машинного обучения и порядок входных признаков. Сохранение порядка признаков в атрибуте `feature_order_` используется при последующей интеграции модели в агентную динамику и исключает ошибки, связанные с несоответствием входных данных.

Следует подчеркнуть, что в процессе обучения не используется кросс-валидация или подбор гиперпараметров, так как целью данного этапа является не оптимизация предсказательной точности на внешних данных, а получение устойчивой аппроксимации реализованного поведенческого правила фирмы, согласованной с динамикой агентной модели. Такой выбор архитектуры и процедуры обучения снижает риск переобучения и обеспечивает стабильность поведения ML-политики при её использовании в составе агентной системы.

1.5 Интеграция ML-политики в динамику агентной модели

Интеграция модели машинного обучения в агентную макроэкономическую модель реализована на уровне отдельного агента фирмы и затрагивает исключительно механизм формирования цены продукции. Все остальные элементы динамики модели, включая рынок труда, производство, потребление, кредитные операции и банковский баланс, остаются неизменными.

Загрузка и использование ML-политики осуществляется в коде агента фирмы, определённого в модуле `agents.py`. Обученная модель машинного обучения загружается из файла `firm_policy.pkl` и используется для вычисления ценовой надбавки на каждом шаге симуляции при наличии активной ML-политики.

В процессе симуляции фирма формирует вектор входных признаков в том же порядке, в котором они использовались при обучении модели (`feature_order_`). Полученное значение ценовой надбавки используется для расчёта цены продукции фирмы, после чего применяется дополнительная числовая защита, ограничивающая допустимый диапазон значений.

Числовая стабилизация реализована с помощью вспомогательной функции `clamp`, определённой в модуле `utils.py`:

```
1 def clamp(value: float, low: float, high: float) -> float:
2     return max(low, min(high, value))
```

Листинг 4: Ограничение диапазона значений

Использование явного ограничения диапазона надбавки гарантирует, что даже в случае неточного предсказания модели машинного обучения цена продукции фирмы остаётся в экономически допустимых пределах и не приводит к числовым или динамическим патологиям в модели.

Важно отметить, что интеграция ML-политики не изменяет порядок событий внутри одного шага симуляции. Фирмы по-прежнему принимают решения в рамках фиксированного временного цикла, включающего обновление ожиданий спроса, определение занятости, производство, выплату заработной платы, реализацию продукции и обслуживание долга. ML-политика используется исключительно как замена аналитического приближения для вычисления одного аргумента — уровня цены.

Такой способ интеграции гарантирует сохранение балансовых соотношений в модели. Цена, вычисленная с использованием ML, влияет на объём продаж и выручку, но не изменяет структуру финансовых потоков, определяемую в модели. Все операции с депозитами, кредитами и капиталом банка по-прежнему выполняются в соответствии с явными правилами, зафиксированными в коде банковского агента.

Таким образом, машинное обучение встраивается в агентную модель как локальная аппроксимация поведенческого правила фирмы, не нарушая институциональных ограничений, балансовой согласованности и общей архитектуры модели.

1.6 Преимущества и ограничения применения машинного обучения

Интеграция методов машинного обучения в агентную макроэкономическую модель позволяет аппроксимировать сложные поведенческие зависимости, которые эндогенно формируются в ходе динамики модели и не могут быть адекватно описаны с помощью простых аналитических правил. Основное преимущество предложенного подхода заключается в том, что ML-политика обучается на реализованном поведении агентов, полученном в рамках корректных и устойчивых прогонов модели, а не навязывается извне в виде нормативного правила.

Использование ML-политики особенно оправдано в контексте результатов анализа чувствительности модели. Как показано в ходе процедуры `history matching`, даже после сужения параметрического пространства (`wave2`) допустимая область параметров (NROY) остаётся достаточно широкой: доля допустимых конфигураций

составляет 32.5%, а медианное значение максимального показателя несоответствия $I_{\max}$ равно 3.79. Одновременно наблюдается существенное сокращение экстремальных несоответствий (95-й перцентиль $I_{\max}$ снижается с 5.67 до 4.83), что указывает на наличие устойчивых, но нелинейных зависимостей в модели.

В таких условиях фиксированные rule-based правила поведения фирм оказываются недостаточно гибкими, так как они не учитывают контекст макроэкономического режима, финансового состояния фирмы и ограничений со стороны банковского сектора одновременно. ML-политика, напротив, аппроксимирует реализованное поведение фирмы как функцию многомерного вектора состояний, что позволяет учитывать взаимодействие реальных и финансовых факторов без явного задания функциональной формы.

Дополнительным преимуществом является согласованность ML-политики с процедурой калибровки модели. Обучающая выборка формируется исключительно на основе репрезентативных прогонов, принадлежащих области допустимых параметров (NROY), что исключает обучение на вырожденных режимах, таких как траектории с нулевым выпуском или занятостью. Это особенно важно с учётом того, что даже в wave2 доля прогонов с нулевой средней занятостью остаётся ненулевой (21.8%), а доля прогонов с нулевым выпуском составляет 15.2%. Таким образом, ML-политика обучается на экономически осмысленных траекториях и не воспроизводит патологические режимы модели.

В то же время предложенный подход обладает рядом принципиальных ограничений. Во-первых, ML-модель аппроксимирует поведение фирм только в пределах пространства состояний, представленного в обучающей выборке. При существенном выходе параметров или состояний за пределы области, охваченной репрезентативными сценариями, предсказания ML-политики могут терять корректность, что требует дополнительных числовых ограничений и защитных механизмов. В реализованной версии модели такая защита обеспечивается явным ограничением диапазона ценовой надбавки.

Во-вторых, несмотря на использование относительно интерпретируемой архитектуры (градиентный бустинг над деревьями решений), ML-политика затрудняет аналитический анализ поведения отдельных агентов по сравнению с простыми rule-based правилами. В частности, прямое аналитическое исследование устойчивости поведенческого правила становится невозможным без дополнительных инструментов интерпретации модели.

Наконец, применение машинного обучения не устраняет структурные ограничения агентной модели, связанные с выбранной институциональной архитектурой, отсутствием инвестиционного сектора, государственного бюджета и ожиданий агентов. В этом смысле ML следует рассматривать не как универсальное средство повышения реалистичности модели, а как инструмент локального усложнения поведенческих

правил в рамках уже заданной экономической структуры.

В целом, полученные результаты показывают, что методы машинного обучения могут быть эффективно интегрированы в агентную макроэкономическую модель для аппроксимации сложных стратегий поведения агентов при условии использования эндогенных данных, предварительной калибровки параметров и строгого соблюдения институциональных и балансовых ограничений модели.